Распознавание ценников на видео торгового зала

Автор: **Цыренов Мэргэн**. Версия: **05.11.2026**.

Постановка задачи

Система извлекает структурированные сведения с ценников по видео движения робота вдоль торговых полок. Обнаружение ценников, объединение наблюдений, выбор читаемых изображений и распознавание текста выполняются единым пайплайном. Результат предназначен для цифрового мониторинга торгового зала. Постановка и реальные исходные материалы предоставлены организаторами хакатона Lenta Tech.

Формат входных и выходных данных

Вход - каталог MP4-видео, включая записи в разрешении 4K. Поворот кадров, размер изображения и шаг обработки задаются конфигурацией. Детектор выделяет ценники, трекер объединяет наблюдения, затем выполняются отбор кропов и OCR.

Выход - `submission.csv` в UTF-8 BOM с 29 столбцами: 18 основных и 11 дополнительных QR-полей. Таблица содержит наименование, ценовые поля, коды, имя видео, временную отметку в миллисекундах и bbox в пикселях исходного кадра. Пустая ячейка обозначает отсутствие достоверно извлечённого значения. Строка соответствует сегменту трека; один физический ценник может иметь несколько сегментов. Схема CSV и артефакты инференса.

Метрики

Основная метрика проекта - доля правильно заполненных содержательных полей: число совпавших с эталоном значений делится на число доступных эталонных полей. Пропущенные соответствия остаются в знаменателе. Micro рассчитывается по суммарным счётчикам, macro - как среднее по видео. Предсказания сопоставляются с эталонными CSV автоматически по видео, времени и bbox. Методика сопоставления.

Полный OOF-пайплайн с EfficientNet rank, PaddleOCR и Qwen3-VL получил **152/3701 = 4.1070% micro**, **4.3018% macro** на пяти видео. Исторический запуск без EfficientNet получил 154/3701 = 4.1610%. Улучшение новым запуском не подтверждено; сравнение не является изолированным экспериментом одного изменения. Ориентир первоначальной заявки - доля более 0.04. Используемый протокол является метрикой проекта и отличается от официального scorer хакатона и простой заполненности CSV. Результаты и счётчики по видео.

Компоненты оцениваются отдельно: YOLO - mAP и precision/recall; EfficientNet - precision 0.8645, recall 0.5286, F1 0.6560 на 2008 OOF-кропах; Qwen OCR - CER 0.5869 на 294 транскрипциях. OCR-сравнение выполнено на development-выборке и не выдаётся за оценку на независимом тесте. Классификация кропов, сравнение OCR.

Валидация

Для YOLO и EfficientNet применяется OOF из пяти folds с группировкой по видео: изображения одного видео не распределяются между обучающей и отложенной частями. Каждая модель обучается независимо. YOLO обучены по 100 эпох, используется `last.pt`; EfficientNet - по 10 эпох. Внешний fold не используется для выбора лучшего checkpoint. Исходная версия YOLO с четырьмя видео сохранена отдельно. Разбиение YOLO, команды OOF-обучения.

При полной видеооценке для каждого видео загружаются соответствующие отложенные YOLO и EfficientNet. SHA256 весов и train-списков YOLO проверены. Старые EfficientNet-checkpoints не содержат train-manifest: принадлежность fold восстановлена по детерминированному разбиению, а held-out предсказания сверены с текущими метками и SHA256 изображений. Автоматические соответствия ценников вручную не проверялись. Эти ограничения относятся к интерпретации полного OOF-результата.

Данные

Основной набор содержит пять реальных видео и эталонные CSV организаторов. YOLO SAM3/Roboflow: 391 кадр, 2593 bbox, пять групп видео. Исходный YOLO-набор: 251 кадр, 2118 bbox, четыре группы. EfficientNet: 2008 изображений, 350 положительных и 1658 отрицательных. OCR: 294 изображения и 107 групп наблюдений ценников. Подготовка наборов, источник видео.

Девять DVC-артефактов содержат обучающие снимки, видео, эталоны, локальные PaddleOCR-веса, YOLO/EfficientNet-checkpoints, примеры инференса и отчёты. Хранилище - закрытый MinIO-бакет `s3://lenta-dvc` с HTTPS endpoint `https://31.31.207.108`. Пользователю выдаются S3-ключи на чтение; SSH-доступ для загрузки не требуется. Ключи хранятся только в локальной конфигурации или переменных окружения. Данные и веса исключены из Git. Состав DVC-артефактов и настройка доступа.

Полные веса Qwen загружаются отдельно из публичного Hugging Face-репозитория; ревизия зафиксирована как `ebb281ec70b05090aa6165b016eac8ec08e71b17`. CPU-профиль использует локальные PaddleOCR-веса из DVC и выполняется без Qwen. Зафиксированная модель Qwen3-VL, CPU-профиль.

Моделирование

Бейзлайн

YOLOv8 обнаруживает ценники, EfficientNet-B0/timm оценивает пригодность изображения для распознавания, EasyOCR извлекает текст. Обучение EfficientNet реализовано через PyTorch Lightning, YOLO - через Ultralytics. EasyOCR на имеющейся OCR-выборке: CER 0.7706, WER 0.9729. Протокол сравнения вариантов.

Основная модель

YOLO → BoT-SORT → геометрические и резкостные фильтры → EfficientNet rank → top-k кропов → PaddleOCR + Qwen3-VL → QR/EAN → сопоставление с каталогом → CSV. В измеренном OOF используются top-2, stride=3, imgsz=1280, вес ранжирования 0.5. EfficientNet оценил 9561 кроп; вероятность читаемости влияет на ранжирование без жёсткого порогового удаления. Параметры полного прогона.

PaddleOCR выполняет CPU-OCR, Qwen3-VL-4B используется как VLM для дополнительного распознавания текста и наименования. Локальный каталог содержит `fullname` и `code`: подтверждённое совпадение кода позволяет уточнить название. Большинство ценовых полей из каталога не восстанавливается. Неоднозначные совпадения сохраняются как предложения. Извлечение полей.

Внедрение

Публичный репозиторий - TM1550/lenta-price-tag-scanner, сдаваемая ветка - `main`. Пакет `lenta_price_tag_scanner` устанавливается через Poetry с lock-файлом. Click предоставляет команды, Hydra - иерархические YAML-конфигурации. DVC pull встроен в train, infer, export и упаковку сервисов. Обучение и инференс разделены; зависимости обучения и VLM вынесены в группы. Инструкции Setup, Train, Production preparation и Infer.

EfficientNet и YOLO экспортируются в ONNX; проверяются ONNX checker и согласованность с PyTorch. MLflow Serving предоставляет HTTP `/invocations` для классификатора кропов и детектора. Полное видео обрабатывается отдельной batch-командой. TensorRT и Triton не входят в подтверждённую поставку. YOLO ONNX и HTTP-сервис, MLflow PythonModel.

Воспроизводимость и инженерная проверка

MLflow записывает гиперпараметры, loss, метрики, Git commit, dirty-флаг, конфигурации и графики. Адрес по умолчанию - `http://127.0.0.1:8080`. Короткие CPU-обучения обеих моделей по две эпохи завершились четырьмя FINISHED runs; сохранены 17 графиков и журналы в `plots/`. Протокол обучения и MLflow.

Чистая установка полного окружения на Linux/Python 3.12 заняла 4 мин 48 с; pip check и сборка wheel/sdist успешны. Короткий CPU-инференс семи кадров сформировал 8 строк и 29 столбцов CSV примерно за 19 с. Текущий набор включает 61 unit-тест; обязательные pre-commit hooks проверяют Python, YAML и документацию. Проверено наличие объектов всех девяти DVC-наборов и скачивание отдельного файла с проверкой TLS в пустой cache. Полное повторное скачивание девяти наборов после миграции не выполнялось. Аудит соответствия.

Ограничения

Низкое разрешение ценников, размытие, ошибки временной привязки и фрагментация треков ограничивают качество. Часть старых MLflow runs не содержит Git commit; их версия подтверждена SHA256-описью исходников. Новые контрольные runs логируют точный commit. Qwen требует больше ресурсов, чем CPU-профиль; полные веса этой модели в DVC не включены. Согласованные ограничения оценки и фактические результаты описаны в OOF-отчёте и описании локального запуска.